


iPAS AI 應用規劃師-科目三 模型重訓練與衡量(範圍 B,D,E)

壹、商業問題：考量模型對未來數據變化穩健性、及模型部署後續監控和重訓練機制針對資料飄移、概念飄移及模型飄移風險。

貳、模型重訓練 (XGBClassifier)

- 資料預處理（缺失、重複、離群值處理）
- 特徵工程（特徵創建、特徵選擇、降維 LDA, PCA...）
- 模型重訓練：更新以時間點切分訓練集(train, validation)、測試集(test)
- 模型驗證(Validation)衡量：挑選模型、調整超參數(學習率、早停、剪枝...)和閾值、評估相關指標，如：Top@N Precision | Recall, KS, PR-Curve
- 模型佈署上線(MLOps):若為初次建模根據實際業務，選擇最適模型演算法
- 模型持續監控：PSI（每月），以評估模型是否飄移
- 數據分析：分析相關領域資料並給長官決策，從數據面角度出發，進而增加特徵欄位、或分析欄位交互作用對模型準確率是否有幫助。

參、模型可解釋性(SHAP 概念圖)



註¹.維度一:X 軸位置→對預測的推力方向數值高於 0 代表該特徵對預測值分數越高，低於 0 則相反；因此離 X 軸愈遠影響愈大。

註².維度二：顏色→特徵值本身大小，紅色表示該值較大

註³. SHAP (SHapley Additive exPlanations) 是一套基於 Shapley Value 的模型解釋框架，屬於一套模型無關的可解釋性框架。

肆、結論及決策

1. 資料科學專案通常涉及多個部門，初步規劃階段需清楚分配工作事務內容領域，確保各方資源能夠即時到位並配合。如：我角色主要以 Data driven 出發，和業務管理單位討論目前需解決之問題，如：此次因模型連續好幾個月無法產出名單，故和資訊單位討論並分析環境是否有出錯處，進一步針對商業問題作模型佈屬環境、資料來源分析、程式語言內容...等後續流程。
2. 持續監控模型效能，因其準確性可能隨著時間會有數據飄移、概念飄移等狀況，如：詐騙手法改變、客戶態樣改變及特徵和目標變數關係改變。另外針對所使用的演算法，可撥空深入研究其理論和實務運用方式，領外對應使用的程式語言語法，並且在開放資料找有興趣主題下載數據值型一次資料科學流程，加深對於機器學習之運用方式和重點。

iPAS AI 應用規劃師-科目三 模型重訓練與衡量(範圍 B,D,E)

伍、題目

1. 模型演算法，訓練集應使用哪種方式學習規則？

- (1) `model.fit(X_train)`
- (2) `model.fit_transform(X_train)`
- (3) `model.transform(X_train)`
- (4) 以上皆是

2. 驗證集資料(Validation)的作用是？

- (1) 更新權重、學習參數
- (2) 泛化能力評估
- (3) 調整超參數、模型選擇
- (4) 以上皆是

陸、解析

1. 參考如下表

步驟	Transformer(學習規則 + 轉換數據)	Estimator(模型只學規則)
訓練集學習	<code>scaler.fit(X_train)</code>	<code>model.fit(X_train, y_train)</code>
訓練集應用	<code>scaler.transform(X_train)</code>	<code>model.predict(X_train)</code>
測試集應用	<code>scaler.transform(X_test)</code>	<code>model.predict(X_test)</code>
合併寫法	<code>fit_transform(X_train)</code>	無此寫法

- 有 `transform` 的東西（前處理）→ 可能用 `fit_transform()`
- 有 `predict` 的東西（模型）→ 只用 `fit()`，然後 `predict()`

2. 參考如下表

資料集	Transformer 角色	Estimator 角色
Train	<code>fit_transform()</code> 學習規則並轉換	<code>fit()</code> 真正學習模型參數
Valid	<code>transform()</code> 只套用規則	監控訓練過程，決定 <code>early stopping</code> ，也用於超參數調整
Test	<code>transform()</code> 只套用規則	只用 <code>predict()</code> ，只在最後評估一次