

探索分析閾值[0.8, 0.95]名單數較舊模型增加原因

一、使用方法論:

SHAP (SHapley Additive exPlanations) 是一套基於 Shapley Value 的模型解釋框架，屬於一套模型無關的可解釋性框架。它同時包含模型無關（如 Kernel SHAP）與模型專屬（如 Tree SHAP、Linear SHAP、Deep SHAP）等多種實作方式。其理論可應用於各種機器學習模型，SHAP 提供多種模型專屬的最佳化演算法，例如 TreeExplainer、LinearExplainer 與 DeepExplainer。因鷹眼模型使用 XGBoost 建立詐欺偵測模型，因此 shap.Explainer() 會自動選用 TreeExplainer 進行解釋，利用樹模型的結構快速計算各特徵對預測結果的貢獻值。SHAP 的目標是通過計算每個特徵對預測 x 的貢獻來解釋實例 x 預測。

$$I_j = \sum_{i=1}^n |\phi_j^{(i)}| \quad \text{平均貢獻大小(1)}$$




圖 1. 平均絕對 SHAP VALUE

1. 整體平均 SHAP value：從該區間交易筆數 14,102 資料中，從整體特徵方向檢視，前九高之特徵有 6 項因子皆為客戶交易行為模式，如：**Flow 平均交易時間差貢獻 (+0.88)**、**開戶至交易日數 (+0.53)**到 **Flow 總轉出金額 (+0.22)**，模型給予較高的詐欺風險評分平均 SHAP 值；這些特徵亦較常出現在每筆交易資料中 Top1_Value ~ Top5_Value 的特徵中(參考表 15)，表示這些 pattern 為近期且最新之詐欺行為主要態樣，也是堆高

這閾值區間名單數的主因。

- 在整體平均 SHAP value 中，其中有幾項反覆出現在 Top1~Top5 的特徵中，如：Flow 平均交易時間差、約轉最後建檔日及交易日時間差、開戶至交易日數、交易通路、單筆交易餘額占比..等，以上皆具較高影響力和出現頻率；另，其中當日交易總轉出雖有出現在整體平均 SHAP Value 中，但是並未在 Top1-Top6 當中，表示該特徵對於模型預測影響頻率雖較低，但其出現時通常會有較大的 SHAP 值。

表 1. Top1-Top6 特徵出現頻率

Feature	Count	Ratio
Flow 平均交易時間差	11,648	16.520%
約轉最後建檔日及交易日時間差	9,811	13.914%
開戶至交易日數	8,830	12.523%
交易通路	8,659	12.281%
單筆交易餘額占比	7,052	10.001%
帳戶餘額	7,004	9.933%

表 2. 前六筆資料各 SHAP 貢獻值

帳號	fraud_prob	Label	Top1_Feature	Top1_Val	Top1_SHAP	Top2_Feature	Top2_Val	Top2_SHAP
2262	94.999%	1	Flow 平均交易時間差	0.1392	2.0245	約轉最後建檔日及交易日時間差	727	0.5378
2152	94.998%	0	Flow 平均交易時間差	0.0245	1.5593	單筆交易餘額占比	60.79	0.6946
2202	94.997%	0	當日交易總轉出	1.1577	1.8479	約轉最後建檔日及交易日時間差	5541	-0.6762
2412	94.997%	0	當日交易總轉出	1.2733	1.7446	約轉最後建檔日及交易日時間差	4712	-0.7295
2292	94.995%	0	當日交易總轉出	1.1578	2.2670	Flow 平均交易時間差	14033	1.6119

2182	94.994%	0	當日交易總轉出	1.6554	2.0548	Flow 總轉入金額	174800	-0.5489
------	---------	---	---------	--------	--------	------------	--------	---------

- 而「交易通路特徵」當中，因當初使用 LabelEncoder(0,1,6,7)，故推測模型極有可能被該特徵影響堆高分數(名目變數被當作有大小之分)導致名單數增加；但從實驗結果檢視，即便多數落在類別 7(銀行資訊交換平台 FEP 跨行 ATM)、6(網路銀行 網銀)，該交易通路模型所貢獻的分數並無明顯高於其它特徵，因此此次重訓練暫且不將改回 OneHotEncoder。
- SHAP 概要圖 (beeswarm)：進而檢視影響模型分數各特徵之貢獻度變化，紅色代表該數值較大、藍色數值則較小，SHAP value 為正數代表該重要特徵與警示戶呈現正向關係，故負數則相反。以最高的「Flow 平均交易時間差」舉例：藍色分布在 shap_value=[0,3]，表示在操作交易時，間隔時間愈短模型給予較高的風險評分數。




圖 2. SHAP 概要圖

- 特徵的風險評分數愈高，詐騙機率越大；另外以開戶至交易日數舉例：當開戶日距離今天愈久，該帳戶被作為警示戶使用機率越高。
- 另外從決策角度檢視這 14,102 筆交易中，僅需前 5 高平均 SHAP value，模型預測能力即可累積近 65%的貢獻度，顯示少數關鍵因素可決定模型的預測能力。這邊選前五高邏輯為從圖形中在 Rank 5 出現拐點 (elbow) 曲線趨於平緩。

表 3

Rank	Mean SHAP	累積貢獻度
Top1	1.2129	23.647%
Top2	0.7472	38.216%
Top3	0.5576	49.087%
Top4	0.4387	57.641%
Top5	0.3565	64.591%




圖 4. Elbow Curve

二、結論

- 由於警示戶標註方式調整為 90 天觀察期，使正樣本數增加，模型得以學習更多詐欺交易行為模式致正樣本行為分佈改變，故模型重新學習決策邊界（更多交易落在 0.8~0.95）。因此原本位於中低風險區間的部分交易，被重新評估為較高風險導致該閾值區間名單大幅增加。SHAP 分析顯示，這些樣本主要受到 **Flow 平均交易時間差、開戶至交易日數、約轉最後建檔日及交易日期時間差及交易通路**等特徵共同影響，而非單一特徵所致。
- 雖然「**當日交易總轉出**」於整體平均 SHAP Value 排名中位居前六大重要特徵之一，但其於 Top1~Top6 特徵出現頻率分析中未列入前六名。顯示該特徵並非普遍存在於所有高風險交易，而是僅出現在部分交易中；然而，一旦出現時，通常具有較大的 SHAP 值，因此對模型預測結果具有較強的影響力。
- 較之下，「**Flow 平均交易時間差**」、「**約轉最後建檔日及交易日期時間差**」、「**開戶至交易日數**」等特徵，不僅平均 SHAP 值較高，也經常出現在各交易之前六大解釋特徵中，顯示其同時具有高影響力（Impact）與高出現頻率（Frequency），可視為模型辨識高風險交易的核心判斷因子。

三、建議及後續追蹤

1. **營運管理處**：目前閾值取[0.99, 0.995]區間，上線資料模型準確率在 27.27%~38.10%、偵測率落在 19.51%~29.27%，在實務上可仿效信用風險評等模型(授信管理處)，提供質化的**專家評分卡**，新增或調整警示戶的重要性特徵因子，亦可剔除較無相關的交易項目，如：證券交易、外匯交易、繳交保費...等，進一步檢視能否有效提升模型準確率、偵測率，以建立自行庫的專屬模型。
2. **資訊處**：資料請每月(日)持續更新滾動，使模型保持最新的學習能力，有助維持準確率，不會產生概念飄移、資料飄移狀況，並且協助將模型 MLOps。
3. **數金處**：現階段**每季**模型重訓練及驗證，防止模型泛化能力下降，持續以數據驅動(data-driven) 分析調整是否可每半年重訓練即可，及分析既有特徵變數態樣，找出詐騙手法 pattern，如：ATM 於下午交易時段 13:00~16:30 較為頻繁；另外，依據營管處所建議特徵納入模型中或者將既有變數剔除。